# Kafka

## 简单说说Kafka是啥?常用在哪些地方?

Kafka就是一个用来处理数据的分布式工具。

#### 它主要有三个功能:

- 1. 消息队列: 就像一个邮局,负责把消息从一个地方发送到另一个地方。
- 2. 安全地保存消息: Kafka会把消息存在硬盘上,这样就不用担心消息丢失了。
- 3. **实时处理数据**:在消息发出的同时进行处理,Kafka还<mark>提供了很多工具</mark>来帮助我们完成这个任务。

#### Kafka主要用在两个地方:

1. **消息队列**:在不同的系统或应用之间实时传输数据,保证数据安全可靠。

2. 数据处理: 实时处理数据流,用来改变或处理数据。

## Kafka比其他消息队列的优势?

当我们谈到Kafka时,总会觉得它是个很棒的消息队列,常常和RocketMQ、RabbitMQ等进行比较。 Kafka相比其他消息队列有以下优点:

- 1. 高性能: 由Scala和Java开发,大量运用批处理和异步思想,每秒可以处理干万级别的消息。
- 2. **兼容性**: Kafka与其他生态系统的兼容性非常好,特别是在大数据和流计算领域。

其实早期的Kafka并不是个完美的消息队列,有些功能不够完善,比如丢失消息、消息可靠性不足等。 这与最早LinkedIn开发Kafka是为了<mark>处理大量日志</mark>有关,本来就不是为了做消息队列的。不过,后来它 在消息队列领域意外获得了成功。

随着时间的推移,Kafka逐渐修复了这些问题。所以,**说Kafka作为消息队列不可靠已经是过去式了!** 现在的Kafka已经成为了一个非常可靠且功能强大的消息队列,受到了许多人的欢迎和青睐。

## 队列模型和Kafka的消息模型的区别

## 队列模型



队列模型就像一个<mark>传递消息的管道,生产者把消息放进队列,消费者从队列里拿消息。每条消息只能被一个消费者使用,消息会在队列里待着,直到被消费或过期。举个例子:生产者发了100条消息,两个消费者通常会各自消费一半的消息(轮流消费)。</mark>

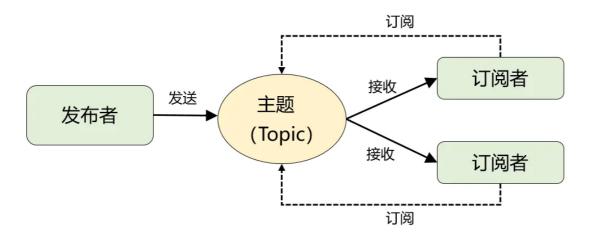
#### 队列模型的问题:

想象这样一种情况:生产者产生的消息需要分发给多个消费者,每个消费者都能收到全部的消息内容。

队列模型在这种情况下就不太好用了。有人会想:为每个消费者创建一个单独的队列,让生产者发送多份。这样做很浪费资源,而且不符合使用消息队列的初衷。

#### 发布-订阅模型: Kafka的消息模型

发布-订阅模型是为了解决队列模型存在的问题而提出的。



发布-订阅模型(Pub-Sub)<mark>通过**主题(Topic) 进行消息传递,就像广播**一样。</mark>发布者发布一条消息, 这条消息会通过主题传递给所有订阅者。不过,<mark>如果用户在消息广播之后才订阅,那么他们将无法收到</mark> 这条消息。

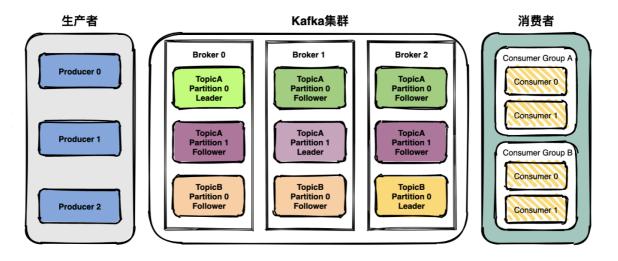
在发布-订阅模型中,<mark>如果只有一个订阅者,那么它和队列模型其实就很相似</mark>了。因此,<mark>发布-订阅模型</mark> 在功能上可以兼容队列模型。

#### Kafka正是采用的发布-订阅模型。

RocketMQ的消息模型和Kafka基本相同。唯一的区别在于Kafka中没有队列这个概念,取而代之的是Partition(分区)。

## Kafka的组件

包括: Producer、Consumer、Broker、Topic、Partition



Kafka系统里,<mark>生产者(Producer)会把消息发送到**主题(Topic)\*** 中,而需要这些消息的消费者(Consumer)则可以订阅这些\*主题(Topic)</mark>,如下图所示:

在这个过程中,我们需要了解Kafka的几个重要概念:

- 1. **生产者 (Producer)** : 负责产生消息。
- 2. **消费者 (Consumer)** : 负责消费消息。
- 3. 代理(Broker): 可以看作是一个独立的Kafka实例。多个Kafka代理组成一个Kafka集群。

此外, 每个代理 (Broker) 里包含了主题 (Topic) 和分区 (Partition) 这两个重要概念:

- **主题 (Topic)**: 生产者把消息发送到特定的主题,消费者通过订阅特定的主题来消费消息。
- **分区(Partition)**: 分区是主题的一部分。一个主题可以有多个分区,同一个主题下的分区可以分布在不同的代理(Broker)上,这也意味着一个主题可以跨越多个代理(Broker)。就像上面的图示一样。

重点提示:在Kafka中,<mark>分区 (Partition) 实际上可以看作是消息队列中的队列</mark>。

# Kafka的多副本机制是什么?它有什么优点?

Kafka为分区(Partition)引入了多副本(Replica)机制。在一个分区里,有一个副本称为leader,其他副本称为follower。我们发送的消息会先发给leader副本,然后follower副本从leader那里同步消息。

生产者和消费者只和leader副本交互。其他副本就像leader副本的备份,它们存在是为了保证消息存储的安全性。如果leader出问题了,系统会从follower中选一个新的leader,但是如果follower和leader同步程度不够,它就不能参选。

#### Kafka的多分区 (Partition) 和多副本 (Replica) 机制有哪些优点呢?

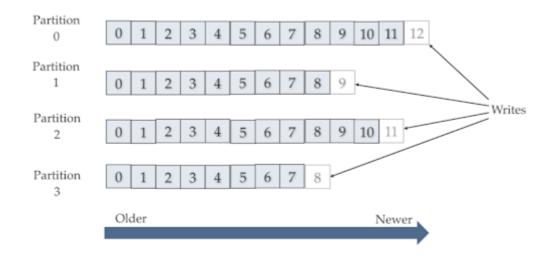
- 1. Kafka可以为特定的主题指定多个分区,而这些分区可以分布在不同的代理(Broker)上,从而提供很好的并发能力(负载均衡)。
- 2. <u>分区可以指定对应的副本数量</u>,<u>这大大提高了消息存储的安全性</u>,<mark>增强了容灾能力</mark>,但相<mark>应地也增加了所需的存储空间。</mark>

## 如何确保Kafka中消息的消费顺序?

在使用消息队列时,我们<mark>经常遇到需要严格按照顺序消费消息的业务场景</mark>。例如,有两条消息对应的数据库操作分别是:

- 1. 修改用户会员等级。
- 2. 根据会员等级计算订单价格。

如果这两条消息的消费顺序不同, 最终结果可能完全不同。



我们知道,Kafka的Partition(分区)是真正存储消息的地方。而Partition(分区)存在于Topic(主题)这个概念中,我们可以为特定的Topic指定多个Partition。

每次向Partition(分区)添加消息时,都会采用追加方式。<mark>Kafka只能保证Partition(分区)中的消息是有序的。</mark>

消息在追加到Partition(分区)时,都会分配一个特定的偏移量(offset)。Kafka通过偏移量(offset)来确保分区内消息的顺序性。

因此,我们有一种<mark>简单的方法来保证消息消费的顺序:**一个Topic只对应一个Partition**。虽然这样可以</mark>解决问题,但它<mark>破坏了Kafka的设计初衷</mark>。

在Kafka中发送一条消息时,可以指定topic、partition、key和data(数据)这四个参数。如果在发送消息时指定了Partition,那么所有消息都会被发送到指定的Partition。此外,具有相同key的消息可以确保只发送到同一个partition,我们可以使用表/对象的ID作为key。

总之,关于如何确保Kafka中消息消费顺序,我们有以下两种方法:

- 1. 一个Topic仅对应一个Partition。
- 2. (推荐) 在发送消息时指定key/Partition。

# Kafka如何确保消息不会丢失

### 生产者可能会丢失消息的情况

当生产者(Producer)调用 send 方法发送消息时,由于网络问题,消息可能没有成功发送。我们不能默认调用 send 方法后消息就发送成功了。为了确定消息发送成功,我们需要判断发送结果。但请注意,Kafka生产者使用 send 方法发送消息实际上是异步操作。我们可以通过 get()方法获取调用结果,但这会使其变为同步操作。通常,我们不推荐这样做,而是添加回调函数。如果消息发送失败,我们可以在检查失败原因后重新发送。此外,建议为生产者的 retries 设置一个合理的重试次数(通常为3),以及重试间隔,以避免消息丢失。

### 消费者可能会丢失消息的情况

Kafka通过偏移量 (offset) 确保消息在分区内的顺序性。消费者在拉取到分区中的某个消息后,会自动提交offset。为了避免消费者在消费消息前崩溃导致的消息丢失,我们可以关闭自动提交offset,并在真正消费完消息后手动提交offset。但这样可能导致消息被重复消费。例如,在消费完消息后还未提交offset时,消费者崩溃,这样消息实际上会被消费两次。

### Kafka可能丢失消息的情况

Kafka通过引入多副本(Replica)机制来保证分区(Partition)中的消息安全性。分区中的多个副本之间会有一个称为leader的副本,其他副本称为follower。我们发送的消息会被发送到leader副本,然后follower副本从leader副本中拉取消息进行同步。生产者和消费者只与leader副本交互。

假设leader副本所在的broker突然崩溃,此时需要从follower副本中选出一个新的leader。但如果 leader的数据尚未被follower副本完全同步,就会导致消息丢失。为了避免这种情况,我们可以设置 acks = all,表示所有ISR列表中的副本都收到消息时,生产者才认为消息发送成功。这是最安全的模式,但会增加延迟。

另外,我们<mark>通常为Topic设置 **replication.factor** >= 3</mark>,以确保每个分区(Partition)至少有3个副本。 虽然这会导致数据冗余,但它确保了数据的安全性。

我们<mark>还需要设置 min.insync.replicas > 1</mark>,这意味着消息至少要被写入到2个副本才算发送成功。在实际生产中,应尽量避免将min.insync.replicas的默认值设为1。为了保证Kafka服务的高可用性,你需要确保replication.factor > min.insync.replicas。我们通常建议设置为replication.factor = min.insync.replicas + 1。

此外,为了减少消息丢失的可能性,我们<mark>可以设置 unclean.leader.election.enable = false</mark>。这样,在leader副本出现故障时,Kafka不会从与leader同步程度达不到要求的follower副本中选择新的leader。这有助于降低消息丢失的风险。

# 如何避免Kafka中的消息重复消费?

在Kafka中,消息可能会被重复消费。原因包括:

- 已消费的数据没有成功提交offset (根本原因)。
- 由于服务器处理业务时间过长或网络连接等原因,Kafka认为服务已经失效,从而触发了分区重新平衡(rebalance)。

为了解决这个问题,我们可以采取以下措施:

- <mark>对消费消息进行幂等性检查</mark>,例如<mark>使用Redis的set或MySQL的主键等自然具有幂等性的功能</mark>。这 种方法是最有效的。
- <mark>将 enable.auto.commit 参数设置为false</mark>,关闭自动提交,并在代码中手动提交offset。这样会引入一个问题:何时提交offset合适?
  - 在处理完消息后提交:这样仍然存在消息重复消费的风险,与自动提交类似。
  - 在拉取到消息后立即提交: 这将导致消息丢失的风险。在允许消息延迟的场景下,通常会采用这种方法。接着,通过定时任务在业务不繁忙(例如凌晨)的时候进行数据补充操作。这样可以在保证系统性能的同时,尽量避免消息的重复消费。

总之,在Kafka中避免消息重复消费需要权衡不同方案的优缺点。可以根据实际业务场景和需求,结合幂等性检查、手动提交offset以及定时任务进行数据补充等策略,来降低消息重复消费的风险。同时,确保系统的稳定性和性能不受影响。